Matriz de antecedentes					
Autores y Año	**Título del estudio**	**Base de datos**	**Metodología**	**Principales hallazgos**	**Relación con la investigación**
Jin, S., Yang, Z., Królczyk, G., Liu, X., Gardoni, P., & Li, Z. (2023). Waste Management, 162, 123-130. doi:10.1016/j.wasman.2023.02.014	Garbage detection and classification using a new deep learning-based machine vision system as a tool for sustainable waste recycling	ScienceDirect (Elsevier). Scopus y Web of Science.	CNN MobileNetV2 + módulo CBAM, reducción PCA (95% varianza), transfer learning. Dataset HUAWEI-40 (14.683 imágenes, 4 categorías). Comparación con AlexNet, VGG16, ResNet50, ResNet101. Prototipo Raspberry Pi 4B.	Exactitud 90,7% (+19,3 pp vs. MobileNetV2 base). Inferencia 600 ms en embebido. Compresión modelo 30,1% con PCA. CBAM: +12,4%; PCA: +10,3%; TL: +8,0%.	Antecedente directo. Provee arquitectura base (MobileNetV2+CBAM), métricas y esquema de validación. Brecha identificada: ausencia dataset colombiano y límite de un objeto por imagen.
Terven, J., Córdova-Esparza, D.M., & Romero-González, J.A. (2023). Machine Learning and Knowledge Extraction, 5(4), 1680-1716. doi:10.3390/make5040083	A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS	MDPI. Scopus y Web of Science.	Revisión sistemática de YOLO v1–v8 y YOLO-NAS. Análisis comparativo en COCO y VOC: mAP, velocidad, parámetros por versión.	YOLOv8 supera versiones anteriores en velocidad y precisión. YOLO-NAS: 52,2% mAP con 20 ms. Diseño anchor-free de YOLOv8 reduce complejidad computacional.	Marco teórico fundamental para selección de arquitectura de detección en tiempo real. Justifica la evolución YOLO y orienta la comparación de variantes para entornos con restricciones de hardware.
Alvarado, M., Mosquera, J., & Ríos, G. (2025). Sensors, 25(10), 3181. doi:10.3390/s25103181	A systematic review of AI-based techniques for automated waste classification	MDPI / PubMed Central. Scopus, Web of Science y PubMed.	Revisión sistemática de 120 artículos (2020–2025). Análisis de CNN, YOLO, ViT, ResNet, MobileNet, EfficientNet. Categorización por dataset, métricas y hardware de despliegue.	ResNet: más implementada (29 estudios). YOLO: 15 estudios. Publicaciones IA-residuos: +47,6% (2023–2024). Pre-trained CNNs dominan con 86 implementaciones identificadas.	Revisión de referencia global. Fundamenta selección de arquitecturas competidoras e identifica brechas: ausencia de contexto latinoamericano y necesidad de datasets industriales especializados.
Rodríguez Chacón, C. (2025). Trabajo de grado. Politécnico Grancolombiano. https://tinyurl.com/43m3s49w	Sistema de clasificación de residuos mediante visión artificial y aprendizaje profundo (WasteCareAI)	Repositorio institucional Politécnico Grancolombiano. Trabajo de grado.	YOLOv11 para clasificación de RSU (plástico, papel, vidrio, metal, cartón, orgánico). Dataset propio en contexto colombiano. Entrenamiento y evaluación en GPU local.	Cartón y plásticos: 76% y 74% mAP@50, insuficientes para uso industrial. Alta similitud visual PET/PVC como limitación principal. Precisión < 90% requerido industrialmente.	Antecedente directo colombiano. Establece línea base que el proyecto debe superar (>90% mAP). Justifica brecha en contexto nacional y sirve como punto de partida metodológico.

GISA (2025). Green Intelligent Systems and Applications.	A systematic literature review of YOLO and IoT applications in smart waste management	Tecno-Científica (Open Access). Bases de datos regionales latinoamericanas.	Revisión sistemática de 78 artículos (2020–2025). YOLO v3–v12 integrados con IoT y cómputo en el borde. Evaluación en entornos industriales de alta velocidad.	YOLO integrado exitosamente con IoT, pero retos de rendimiento en alta velocidad industrial sin resolver. YOLOv8: versión más adoptada en gestión de residuos.	Fundamenta elección de YOLO y contextualiza retos no resueltos. Justifica investigación en clasificación multi-objeto a velocidades industriales.
Lin, K., Zhao, Y., Gao, X., et al. (2022). Environmental Science and Pollution Research, 29, 91081-91095. doi:10.1007/s11356-022-22167-w	Applying a deep residual network coupling with transfer learning for recyclable waste sorting	Springer Nature. Scopus y Web of Science.	RWNet: ResNet-18/34/50/101/152 con transfer learning ImageNet. Cyclical learning rate y data augmentation. Dataset 6 categorías. Métricas: accuracy, F1, ROC.	RWNet-152: 88,8% exactitud. RWNet-101: mejor precisión ponderada (89,9%). TL mejora rendimiento significativamente. Cyclical LR estabiliza convergencia.	Benchmark para ResNet con TL en residuos. Justifica uso de TL y proporciona métricas de comparación para el primer objetivo específico del estudio.
Zhou, Y., Lin, L., & Wang, T. (2024). AIP Advances, 14(12), 125012. doi:10.1063/5.0244795	Garbage classification detection system based on the YOLOv8 algorithm	AIP Publishing. Scopus y Web of Science.	YOLOv8 para 44 categorías de basura. Dataset 15.000 imágenes. Validación en vehículos autónomos. Evaluación de FPS y precisión.	YOLOv8: ~35 FPS, exactitud 90%. Validado en vehículos no tripulados. 44 categorías demuestran capacidad de generalización.	Valida YOLOv8 para tiempo real con alta variedad de categorías. Referencia de velocidad (35 FPS) y exactitud para el requisito de >15 FPS del segundo objetivo.
Riyadi, S., Andriyani, A.D., & Masyhur, A.M. (2024). Revue d'Intelligence Artificielle, 38(4). doi:10.18280/ria.380404	Classification of recyclable waste using deep learning: A comparison of YOLO models	IIETA. Scopus.	YOLOv5 vs. YOLOv8 en dataset WaRP de planta recicladora. Evaluación precisión, recall, mAP50, velocidad. Análisis por clase de material.	YOLOv8 supera YOLOv5: mAP50 54,6% vs. 40,6%. Diseño anchor-free logra mejoras sustanciales. Rendimiento variable entre categorías.	Comparación directa en dataset industrial. Evidencia limitaciones < 90% para materiales similares, justificando el enfoque del presente estudio.
Feng, Z., Yang, J., Chen, L., Chen, Z., & Li, L. (2022). Int. J. Environ. Res. Public Health, 19(23), 15987. doi:10.3390/ijerph19231598	An intelligent waste-sorting and recycling device based on improved EfficientNet	MDPI. Scopus, Web of Science y PubMed.	GECM-EfficientNet con módulos ECA y CA. Entrenamiento en TrashNet + dataset propio. Despliegue en Raspberry Pi 4B. Comparación con EfficientNetB0, MobileNetV2/V3, ResNet50.	94,54% exactitud, 1,23 M parámetros, 146 ms en Raspberry Pi 4B. Supera EfficientNetB0 (88,81%). Módulos ECA+CA mejoran extracción de características.	Demuestra viabilidad de modelos ligeros con atención para embebidos. Referencia para clasificación en tiempo real de bajo costo en contexto industrial colombiano.
Kroell, N., Chen, X., Greiff, K., & Feil, A. (2022). Waste Management, 149, 259-290. doi:10.1016/j.wasman.2022.05.015	Optical sensors and machine learning algorithms in sensor-based material flow characterization for	ScienceDirect (Elsevier). Scopus y Web of Science.	Revisión sistemática de 87 artículos sobre NIR, VIS, HSI y ML para caracterización de flujos de material en reciclaje	NIR: tecnología dominante en plantas industriales. ML mejora precisión vs. métodos quimiométricos. Tiempo de procesamiento	Fundamenta el estado del arte en clasificación industrial con NIR (TOMRA). Compara visión RGB propuesta frente a

	mechanical recycling: A systematic literature review		mecánico. Análisis de aplicabilidad industrial.	en línea: limitación principal para adopción industrial.	NIR. Identifica brechas en integración deep learning + sensores.
Riba, J.R., Cantero, R., Riba-Mosoll, P., & Puig, R. (2022). Polymers, 14(12), 2475. doi:10.3390/polym14122475	Post-consumer textile waste classification through near-infrared spectroscopy using an advanced deep learning approach	MDPI. Scopus, Web of Science y PubMed.	CNN aplicada a espectros NIR de 370 muestras textiles (7 fibras puras + mezclas binarias). Sensores de fibra óptica en proceso continuo industrial.	100% clasificación en fibras puras, 90–100% en mezclas binarias. CNN supera métodos quimiométricos. Compatible con automatización industrial a escala.	Demuestra que NIR + deep learning supera limitaciones para materiales similares. Analogía directa con el problema de plásticos visualmente similares abordado en la investigación.
Abdu, H., & Noor, M.H.M. (2022). IEEE Access, 10, 128151-128165. doi:10.1109/ACCESS.2022.3226689	A survey on waste detection and classification using deep learning	IEEE. Scopus y Web of Science.	Revisión de 85 estudios (2015–2022): CNN, YOLO, R-CNN, ResNet. Datasets: TrashNet, TACO, MJU-Waste. Análisis de métricas y aplicaciones prácticas.	CNN pre-entrenadas dominan clasificación; YOLO lidera en tiempo real. Principales retos: escasez de datos etiquetados, variabilidad intra-clase, iluminación industrial.	Referencia comprehensiva hasta 2022. Justifica el enfoque metodológico e identifica gaps en aplicaciones industriales reales, validando la pregunta de investigación propuesta.
Lahoti, J., Sn, J., Krishna, M.V., et al. (2024). PeerJ Computer Science, 10, e1957. doi:10.7717/peerj-cs.1957	Multi-class waste segregation using computer vision and robotic arm	PeerJ Computer Science. Scopus y Web of Science.	YOLOv5 para detección multi-clase (papel, plástico, metal, vidrio). Integración con brazo robótico. Dataset 5 categorías. Evaluación end-to-end.	Sistema YOLOv5 + brazo robótico funcional. YOLO supera CNN/RCNN para múltiples objetos simultáneos. Clasificación multi-clase en tiempo real con integración física.	Referencia directa para el tercer objetivo: protocolos visión-robótica. Demuestra viabilidad técnica de integrar YOLO con actuadores físicos.
Thao, L.Q. (2023). J. Material Cycles and Waste Management, 25, 3791-3800. doi:10.1007/s10163-023-01796-4	An automated waste management system using artificial intelligence and robotics	Springer Nature. Scopus y Web of Science.	CNN para clasificación + brazo robótico integrado. Comunicación inalámbrica entre módulos. Hardware: Raspberry Pi + actuadores. Evaluación end-to-end.	99% tasa de éxito en clasificación CNN. Sistema completamente integrado: captura, clasificación, actuación y comunicación inalámbrica. Mejora seguridad laboral.	Modelo de referencia para integración visión-robótica. El 99% valida factibilidad técnica. Referencia para diseño de protocolos del tercer objetivo específico.
Alrayes, F.S., Asiri, M.M., Maashi, M.S., et al. (2023). Urban Climate, 49, 101483. doi:10.1016/j.uclim.2023.101483	Waste classification using vision transformer based on multilayer hybrid convolution neural network	ScienceDirect (Elsevier). Scopus y Web of Science.	Modelo híbrido ViT + CNN multicapa. Evaluado en TrashNet. Comparación con ResNet50, MobileNet. Análisis de precisión, recall y F1 por clase.	ViT híbrido supera ResNet50 y MobileNet en TrashNet. Auto-atención captura relaciones globales en materiales visualmente complejos.	Justifica inclusión de ViT como arquitectura competidora. Evidencia que modelos de atención pueden superar CNN convencionales para residuos de alta similitud

					visual.
Sayem, F.R., et al. (2024). Neural Computing and Applications, 36, 24677-24700. doi:10.1007/s00521-024-10855-2	Enhancing waste sorting and recycling efficiency: robust deep learning-based approach for classification and detection	Springer Nature. Scopus y Web of Science.	Múltiples arquitecturas evaluadas en dataset WaRP (28 clases, >10.000 imágenes de planta recicladora real). Comparación Mask R-CNN, YOLOv5, ResNet50, RWC-Net propuesto.	WaRP (2023): benchmark industrial con objetos superpuestos e iluminación deficiente. RWC-Net supera Mask R-CNN y YOLO en condiciones complejas.	Introduce WaRP como benchmark industrial representativo. Evidencia limitaciones de precisión en entornos reales con solapamiento, justificando directamente el problema de investigación.
Wu, F., & Lin, H. (2022). Frontiers in Environmental Science, 10, 1043843. doi:10.3389/fenvs.2022.1043843	Effect of transfer learning on the performance of VGGNet-16 and ResNet-50 for the classification of organic and residual waste	Frontiers Media. Scopus y Web of Science.	VGGNet-16 y ResNet-50 con/sin transfer learning para clasificación binaria de residuos. Análisis de accuracy, convergencia y generalización.	TL mejora significativamente ambas arquitecturas. ResNet-50 con TL supera VGGNet-16. Convergencia más rápida y mejor generalización con fine-tuning.	Cuantifica el beneficio del TL, fundamentando el primer objetivo. Justifica uso de modelos pre-entrenados en ImageNet como punto de partida.
Yudin, D., Zakharenko, N., Smetanin, A., et al. (2024). Engineering Applications of Artificial Intelligence. doi:10.1016/j.engappai.2023.107542	Hierarchical waste detection with weakly supervised segmentation in images from recycling plants	ScienceDirect (Elsevier). Scopus y Web of Science.	Modelo H-YC jerárquico con segmentación débilmente supervisada en WaRP (28 clases). Condiciones industriales reales: solapamiento, iluminación variable, conveyor.	H-YC mejora detección en WaRP. Segmentación con supervisión débil (solo etiquetas de clase, sin máscaras). Maneja objetos superpuestos en conveyor industrial.	Referencia para condiciones industriales reales. Establece nivel de complejidad técnica requerido en plantas de clasificación, alineado con los objetivos propuestos.
Singh, M.K., et al. (2023). Process Safety and Environmental Protection, 179, 593-602. doi:10.1016/j.psep.2023.09.036	Hyperspectral imaging-based classification of post-consumer thermoplastics for plastics recycling using ANN	ScienceDirect (Elsevier). Scopus y Web of Science.	Cámara hiperespectral NIR (1000–1700 nm). Segmentación por entropía y contrast stretching. Red neuronal feedforward + SoftMax para clasificación polimérica.	89,5% exactitud en polímeros post-consumo. NIR-HSI distingue ABS, PS, PP, PE, PET, PVC de alta similitud visual. Tiempo de procesamiento HSI: limitante industrial.	Referencia para NIR industrial (TOMRA). Evidencia limitaciones de NIR para materiales contaminados, justificando complementariedad con visión RGB propuesta.
Hussain, M. (2024). IEEE Access, 12, 42816-42833. doi:10.1109/ACCESS.2024.3375201	YOLOv1 to v8: Unveiling each variant – a comprehensive review of YOLO	IEEE. Scopus y Web of Science.	Revisión técnica de YOLO v1–v8. Análisis de innovaciones arquitecturales, precisión y velocidad. Diseño anchor-free v8. Comparación en COCO y VOC.	YOLOv8: diseño anchor-free y cabeza desacoplada establece nuevo estado del arte. Evolución YOLO: incremento consistente de mAP con reducción de parámetros.	Referencia técnica esencial para selección de versión YOLO. Proporciona fundamento comparativo para la elección arquitectural del sistema propuesto.

Khanam, R., & Hussain, M. (2024). arXiv preprint arXiv:2410.17725.	YOLOv11: An overview of the key architectural enhancements	arXiv (preprint, en proceso de publicación en revista indexada).	Descripción técnica de YOLOv11: cabeza C3K2, SPPF con PSA. Benchmarks en COCO. Comparación con YOLOv8, YOLOv10, YOLO-NAS en mAP, velocidad y parámetros.	YOLOv11: 22% menos parámetros que YOLOv8m con precisión comparable. PSA mejora detección de objetos pequeños. Inferencia más eficiente en hardware embebido.	Justifica actualización de YOLOv8 a YOLOv11. Fundamento técnico para mejoras en detección multi-objeto y objetos pequeños en el entorno industrial propuesto.
Tian, X., Shi, L., Luo, Y., & Zhang, X. (2024). IEEE Access, 12. doi:10.1109/ACCESS.2024.3385632	Garbage classification algorithm based on improved MobileNetV3	IEEE. Scopus y Web of Science.	MobileNetV3 mejorado con CBAM y capas depthwise separable. Dataset de residuos domésticos. Comparación con MobileNetV2, ShuffleNet, EfficientNetB0.	94,26% exactitud, 261,7 ms de inferencia en embebido. Supera MobileNetV2 en velocidad manteniendo precisión comparable.	Complementa arquitectura base (Jin 2023) con versión más reciente de MobileNet. Valida la familia para hardware de bajo costo, relevante para el objetivo de >15 FPS.
Tan, M., & Le, Q.V. (2021). Proceedings ICML 2021, PMLR, 10096-10106.	EfficientNetV2: Smaller models and faster training	PMLR. Scopus.	EfficientNetV2 con compound scaling mejorado, Fused-MBConv y entrenamiento progresivo. Evaluación en ImageNet, CIFAR-10/100, Flowers.	Entrena 11× más rápido que EfficientNetV1; 6,8× menos parámetros que ViT. 87,3% top-1 en ImageNet.	Introduce EfficientNetV2 mencionada como brecha en Jin (2023). Justifica su inclusión como arquitectura competidora en el estudio propuesto.
Islam, M.S., et al. (2025). PLOS ONE, 20(6), e0324294. doi:10.1371/journal.pone.0324294	Towards sustainable solutions: Effective waste classification framework via enhanced deep CNNs	PLOS ONE. Scopus, Web of Science y PubMed.	DenseNet201 personalizado con atención SE + ramas CNN paralelas. Dataset TrashNet. Comparación con MobileNetV3+LSTM, EfficientNet-B2, DenseNet121/169.	Supera MobileNetV3+LSTM (81%) y EfficientNet-B2 (75%). DenseNet121/169: 95% exactitud. Módulos SE mejoran clasificación de materiales con características visuales similares.	Estado del arte 2025 con DenseNet y SE. Valida efectividad de SE para categorías difíciles de distinguir, relevante para el problema de materiales visualmente similares propuesto.
Liu, Y., Shi, Y., & Fan, X. (2021). Sustainability, 13(21), 11572. doi:10.3390/su13211572	Recycling waste classification using vision transformer on portable device	MDPI. Scopus y Web of Science.	Vision Transformer (ViT) para clasificación de residuos. Evaluado en TrashNet (6 categorías). Comparación con CNN. Análisis de factores: transfer learning, tamaño de patch.	ViT: 96,98% exactitud en TrashNet, superando métodos CNN. TL esencial para ViT con datos limitados. Mala clasificación por reflexión superficial o solapamiento. Desplegado en dispositivo portátil.	Primera demostración de ViT superando CNN en residuos. Introduce ViT como competidor relevante. Justifica TL como estrategia indispensable con datos limitados de residuos.
Single, S., Iranmanesh, S., & Raad, R. (2023). Information, 14(11), 633. doi:10.3390/info14110633	RealWaste: A novel real-life data set for landfill waste classification using deep learning	MDPI. Scopus y Web of Science.	Creación de RealWaste: 4.752 imágenes de residuos reales en vertedero. Condiciones variables de iluminación y	RealWaste mejora rendimiento en condiciones de campo real vs. laboratorio. Modelos entrenados en TrashNet:	Evidencia el problema de transferibilidad entre datasets de laboratorio y condiciones reales. Justifica la necesidad de

			cámara. Evaluación de CNN (VGG, ResNet, EfficientNet) entrenadas en el nuevo dataset.	degradación significativa al evaluar en RealWaste. Diversidad de condiciones crítica para generalización.	recolección de datos en el entorno industrial colombiano real.
Bashkirova, D., Abdelfattah, M., Zhu, Z., et al. (2022). Proceedings IEEE/CVF CVPR 2022, 21147-21157.	ZeroWaste dataset: Towards deformable object segmentation in cluttered scenes	IEEE CVPR 2022. Scopus y Web of Science.	ZeroWaste: dataset de segmentación de residuos deformables en escenas desordenadas de planta recicladora real. Anotaciones pixel-level con 4 clases. Benchmark Mask R-CNN, Swin-T.	Los modelos existentes fallan en escenas industriales complejas con objetos deformables y solapados. Modelos entrenados en TrashNet no generalizan a ZeroWaste. Segmentación pixel-level necesaria en entornos industriales.	Establece el reto de generalización desde datasets simples a condiciones industriales. Justifica los objetivos de detección y seguimiento en tiempo real con materiales deformables en conveyor.
Mao, W.L., Chen, W.C., Wang, C.T., & Lin, Y.H. (2021). Resources, Conservation and Recycling, 164, 105132. doi:10.1016/j.resconrec.2020.105132	Recycling waste classification using optimized convolutional neural network	ScienceDirect (Elsevier). Scopus y Web of Science.	CNN optimizada con Dropout y Batch Normalization para clasificación de reciclables. Análisis de profundidades de red. Comparación con VGG, ResNet, Inception.	CNN optimizada: alta precisión con menor complejidad. Dropout + BN previene sobreajuste en datasets pequeños. Profundidades moderadas: mejor balance precisión/velocidad.	Establece principios de diseño de CNN eficientes. Hallazgos sobre regularización relevantes para el primer objetivo: estrategias de entrenamiento y aumento de datos.
Bobulski, J., & Kubanek, M. (2021). Applied Computational Intelligence and Soft Computing, 2021, 6626948. doi:10.1155/2021/6626948	Deep learning for plastic waste classification system	Hindawi. Scopus.	CNN para clasificación de 7 tipos de plásticos (PET, HDPE, PVC, LDPE, PP, PS, otros). Dataset propio de 600 imágenes con variaciones de iluminación y ángulo. Análisis de augmentation.	88,5% exactitud en plásticos con alta similitud visual. Similitud PET/PVC/PS: mayor desafío. Augmentation mejora robustez en 8,3 pp. Supera SVM (67,2%).	Referencia directa para el problema de plásticos visualmente similares. Cuantifica la dificultad de distinguir tipos de plástico por apariencia visual, justificando técnicas de aumento de datos especializadas.
Zhang, Q., Yang, Q., Zhang, X., et al. (2022). Resources, Conservation and Recycling, 181, 106235. doi:10.1016/j.resconrec.2022.106235	A multi-label waste detection model based on transfer learning	ScienceDirect (Elsevier). Scopus y Web of Science.	Modelo multi-etiqueta con TL para detección simultánea de múltiples residuos. Dataset de 8.000 imágenes multi-objeto. Backbone ResNet-50 + detector multi-label.	Modelo multi-label supera single-label en escenas con múltiples residuos. TL permite convergencia con dataset limitado. mAP 76% en 6 categorías simultáneas.	Aborda múltiples objetos simultáneos en el mismo frame, relevante para conveyor industrial. Justifica el enfoque de detección YOLO sobre clasificación simple en el primer objetivo.

Konstantinidis, F.K., et al. (2023). Resources, Conservation and Recycling, 199, 107244. doi:10.1016/j.resconrec.2023.107244	Multi-modal sorting in plastic and wood waste streams	ScienceDirect (Elsevier). Scopus y Web of Science.	Sistema multimodal RGB + NIR para clasificación de residuos plásticos y madera en planta industrial real. Comparación de modalidades individuales vs. fusión.	Fusión RGB+NIR supera cada modalidad individual, especialmente para materiales oscuros y plásticos contaminados. Sistema multimodal alcanza >92% en condiciones industriales.	Evidencia que sistemas híbridos RGB+NIR superan tecnologías individuales. Justifica el valor añadido de la visión RGB propuesta frente a sistemas NIR y su complementariedad con TOMRA.
Hu, Y., Yang, Z., Qu, Q., et al. (2025). Proc. Institution of Mechanical Engineers, Part C. doi:10.1177/09544062251339384	A new machine vision-based industrial robot system for garbage management	SAGE Journals. Scopus y Web of Science.	Brazo robótico con MobileNetV3 + YOLOv4 optimizado. Algoritmo de agarre por torque mínimo externo. Dataset 4 categorías. Evaluación de precisión individual y general del sistema end-to-end.	90% precisión en clasificación individual; 91,2% general. 100% tasa de clasificación con múltiples residuos no adherentes. Combinación MobileNetV3+YOLOv4 optimiza velocidad para control robótico.	Referencia directa para el tercer objetivo: integración visión-robótica industrial. Establece métricas alcanzables en sistemas end-to-end y valida la factibilidad técnica de la integración YOLO + actuadores físicos.
Li, N., & Chen, Y. (2023). Urban Climate, 49, 101462. doi:10.1016/j.uclim.2022.101462	Municipal solid waste classification and real-time detection using deep learning methods	ScienceDirect (Elsevier). Scopus y Web of Science.	Múltiples arquitecturas deep learning (CNN, YOLO, Faster R-CNN) para clasificación y detección en tiempo real de RSU municipal. Comparación de FPS y mAP por categoría.	YOLO supera Faster R-CNN en velocidad con precisión comparable. Categorías de residuos contaminados: mayor tasa de error. Modelos ligeros necesarios para hardware de bajo costo.	Benchmarks de detección en tiempo real para RSU, alineado con el segundo objetivo (>15 FPS). Justifica YOLO sobre detectores de dos etapas para el requisito de tiempo real del sistema propuesto.
Zhao, R., et al. (2024). Waste Management, 190, 398-408. doi:10.1016/j.wasman.2024.06.028	Multi-target detection of waste composition in complex environments based on an improved YOLOX-S model	ScienceDirect (Elsevier). Scopus y Web of Science.	YOLOX-S mejorado para detección multi-objetivo con oclusión, solapamiento y variación de escala. Dataset propio de planta recicladora industrial.	YOLOX-S mejorado: mAP 85,02% en condiciones complejas. Maneja oclusión parcial y solapamiento mejor que YOLOv5. Plásticos de color similar: desafío persistente.	Establece el nivel de precisión alcanzable (~85%) en condiciones industriales con solapamiento. Evidencia que incluso modelos mejorados no alcanzan el 90% requerido, justificando directamente la brecha de investigación.
Neelakandan, S., et al. (2022). Chemosphere, 308, 136046. doi:10.1016/j.chemosphere.2022.136046	Metaheuristics with deep transfer learning enabled detection and classification for industrial waste management	ScienceDirect (Elsevier). Scopus, Web of Science y PubMed.	Metaheurísticos (PSO) + transfer learning (DenseNet) para detección y clasificación de residuos industriales. Optimización automática de hiperparámetros.	PSO + DenseNet: 93,7% exactitud. Mejora +4,2 pp vs. ajuste manual. Reduce tiempo de ajuste de hiperparámetros significativamente.	Introduce optimización metaheurística de hiperparámetros como complemento al entrenamiento manual. Relevante para el primer objetivo: estrategias de entrenamiento con datos

					colombianos limitados.
Rahman, M.W., Islam, R., Hasan, A., et al. (2022). J. King Saud Univ. – Comp. Info. Sci., 34(5), 2072-2087. doi:10.1016/j.jksuci.2020.05.006	Intelligent waste management system using deep learning with IoT	ScienceDirect (Elsevier). Scopus y Web of Science.	CNN para clasificación de residuos integrada con sensores IoT (humedad, peso, nivel). Comunicación MQTT en tiempo real. Raspberry Pi como unidad central.	Sistema IoT-CNN: >92% precisión con datos de múltiples sensores. Integración de datos IoT mejora la toma de decisiones. Raspberry Pi suficiente para tiempo real con modelos ligeros.	Valida integración CNN + Raspberry Pi en sistemas IoT, relevante para el objetivo de clasificación en hardware de bajo costo. Referencia para el segundo objetivo: configuración de hardware de despliegue.
Majchrowska, S., et al. (2022). Waste Management, 150, 26-36. doi:10.1016/j.wasman.2022.06.012	Deep learning-based waste detection in natural and urban environments	ScienceDirect (Elsevier). Scopus y Web of Science.	Detección de residuos en escenas naturales y urbanas. Dataset TACO + datos propios. Evaluación de YOLO y Faster R-CNN bajo condiciones variables.	Modelos pierden hasta 25% mAP en entornos no controlados vs. laboratorio. La diversidad de fondos e iluminación es el factor más crítico para la generalización.	Evidencia la brecha de generalización laboratorio-condiciones reales. Fundamenta la necesidad de datasets robustos que capturen la variabilidad real del entorno industrial colombiano.
Satav, A.G., Kubade, S., Amrutkar, C., et al. (2023). Int. J. on Interactive Design and Manufacturing, 17, 1-18. doi:10.1007/s12008-023-01344-6	A state-of-the-art review on robotics in waste sorting: scope and challenges	Springer Nature. Scopus y Web of Science.	Revisión sistemática de sistemas robóticos para clasificación de residuos: brazos robóticos, manipuladores, sistemas de agarre e integración con visión artificial.	Principales desafíos robóticos: agarre de objetos irregulares, velocidad vs. throughput industrial, variación de materiales. La integración visión-robótica es el cuello de botella para adopción industrial.	Revisión de referencia para el tercer objetivo: protocolos visión-robótica. Identifica desafíos técnicos concretos para la especificación de protocolos y diseño de validación empírica o simulada.
Ha, V.T., Thuong, T.T., & Ha, V.T. (2023). LNNS, 602. doi:10.1007/978-3-031-22200-9_44	Developing an intelligent waste sorting with 6DOF robotic arm	Springer Nature. Scopus.	Sistema de clasificación con brazo 6DOF, módulo de visión artificial y unidad de control. Análisis de imágenes analíticas para reconocimiento de categorías en conveyor.	Sistema funcional de clasificación con brazo 6DOF y visión integrada. Velocidad de ciclo adecuada para demostración en laboratorio.	Referencia concreta de arquitectura para el tercer objetivo. Diseño de comunicación módulo visión-control del brazo 6DOF provee referencia para los protocolos de comunicación a especificar.

Kirillov, A., Mintun, E., Ravi, N., et al. (2023). Proc. ICCV 2023. arXiv:2304.02643.	Segment Anything	IEEE ICCV 2023. Scopus.	SAM: modelo de segmentación universal entrenado con >1 mil millones de máscaras en 11 millones de imágenes. Evaluación zero-shot y few-shot en 23 datasets.	SAM logra segmentación competitiva en modo zero-shot frente a modelos supervisados específicos. ViT-H como encoder permite características robustas sin re-entrenamiento.	Introduce SAM para el segundo objetivo: integrar detección, segmentación y seguimiento. Arquitectura de segmentación universal que puede complementar YOLO en la pipeline industrial propuesta.
Casao, S., et al. (2024). Proc. IEEE/RSJ IROS 2024, 5852-5858. doi:10.1109/IROS58592.2024.10802296	SpectralWaste dataset: Multimodal data for waste sorting automation	IEEE/RSJ IROS 2024. Scopus y Web of Science.	SpectralWaste: dataset multimodal (RGB + espectral NIR) de residuos en conveyor industrial real, 28 clases, anotaciones pixel-level. Benchmark detección y clasificación multimodal vs. RGB solo.	Fusión RGB+NIR mejora clasificación de plásticos contaminados y de colores similares. Dataset de conveyor industrial más representativo que datasets de laboratorio.	Dataset de referencia para validación en condiciones industriales reales. Relevante para comparar el sistema RGB propuesto con sistemas multimodales y como benchmark para categorías difíciles.
Wang, A., Chen, H., Liu, L., et al. (2024). arXiv:2405.14458 / NeurIPS 2024.	YOLOv10: Real-time end-to-end object detection	arXiv / NeurIPS 2024. Scopus.	YOLOv10: eliminación de NMS mediante asignación de etiquetas consistente dual. Evaluación en COCO. Comparación con YOLOv8, YOLOv9, YOLO-NAS en latencia end-to-end y mAP.	YOLOv10 elimina NMS, reduciendo latencia end-to-end en 2 ms sin pérdida de mAP. YOLOv10-S/M superan YOLOv8 equivalente en COCO. Menor complejidad para despliegue en hardware limitado.	Presenta YOLOv10 como alternativa potencialmente superior a YOLOv8. La eliminación de NMS es relevante para latencia end-to-end en aplicaciones industriales donde >15 FPS es crítico.
Tamin, O., Moung, E.G., Dargham, J.A., et al. (2023). Int. J. Electrical and Computer Engineering, 13(3), 3407-3419. doi:10.11591/ijece.v13i3.pp3407-3419	A review of hyperspectral imaging-based plastic waste detection state-of-the-arts	IAES Institute (IJECE). Scopus.	Revisión de NIR-HSI para detección de residuos plásticos. Análisis de tipos de polímeros detectables, limitaciones técnicas, costos y comparación con métodos RGB.	NIR-HSI logra NER de 98% para polímeros específicos. Equipos HSI: costosos y voluminosos. Plásticos negros: mayor desafío para NIR. Integración de cámara RGB mejora detección de bordes y colores.	Fundamenta la justificación técnica para visión RGB (más económico) frente a NIR industrial. Evidencia limitaciones económicas de NIR para el sector reciclador colombiano, validando el enfoque propuesto.
Taneepanichskul, N., Purkiss, D., & Miodownik, M. (2022). Frontiers in Sustainability, 3, 901885. doi:10.3389/frsus.2022.901885	A review of sorting and separating technologies suitable for compostable and biodegradable plastic packaging	Frontiers Media. Scopus y Web of Science.	Revisión de tecnologías NIR, RGB, Raman, flotación y electrostática para plásticos compostables y biodegradables. Análisis de limitaciones con materiales contaminados.	NIR estándar falla en plásticos contaminados con alimentos. PLA indistinguible de PET por NIR con contaminación. NIR hiperespectral avanzado mejora discriminación pero aumenta el costo.	Evidencia limitaciones fundamentales de NIR para materiales de alta similitud química y visual. Justifica el enfoque de deep learning visual propuesto y la comparación con sistemas

					industriales actuales.
Zhang, Q., Yang, Q., Zhang, X., et al. (2022). Waste Management, 148, 142-150. doi:10.1016/j.wasman.2022.05.031	Waste image classification based on transfer learning and CNN under real-world noise perturbation	ScienceDirect (Elsevier). Scopus y Web of Science.	CNN con TL evaluada bajo perturbaciones reales: variación de iluminación, blur, JPEG, ruido gaussiano. Dataset TrashNet + perturbaciones sintéticas y reales.	Precisión cae hasta 18% bajo perturbaciones severas sin robustificación. Augmentation de ruido mejora robustez en 12 pp. TL vulnerable ante ruido severo.	Evidencia la vulnerabilidad de CNN ante condiciones industriales reales (iluminación variable, polvo). Fundamenta el primer objetivo: estrategias de aumento de datos para condiciones industriales colombianas.
Akyol, K., & Karacı, A. (2023). Frontiers in Environmental Science, 11, 1228732. doi:10.3389/fenvs.2023.1228732	GCNet: A novel waste classification model based on EfficientNetV2 and Vision Transformer fusion	Frontiers Media. Scopus y Web of Science.	GCNet: fusión de EfficientNetV2, Vision Transformer y DenseNet con TL. Dataset de 41.650 imágenes con augmentation. Comparación con modelos individuales y enfoques de fusión.	GCNet: buena convergencia, alta recall y tiempo de reconocimiento corto. Fusión EfficientNetV2 + ViT + DenseNet supera cada arquitectura individual.	Presenta GCNet como arquitectura ensemble de referencia para clasificación avanzada. Justifica modelos de fusión para el problema de materiales similares y provee referencia comparativa para el estudio propuesto.
Liang, S., & Gu, Y. (2021). Waste Management, 126, 247-257. doi:10.1016/j.wasman.2021.03.012	A deep CNN to simultaneously localize and recognize waste types in images	ScienceDirect (Elsevier). Scopus y Web of Science.	CNN de un solo paso para localización y reconocimiento simultáneo de tipos de residuos. Dataset de 8 categorías con anotaciones bounding box. Escenas con múltiples objetos.	Localización y reconocimiento simultáneo con alta precisión en múltiples objetos. Supera enfoques de dos etapas en velocidad. Resultados sólidos con fondos variables y múltiples residuos.	Relacionado directamente con el segundo objetivo: integración de detección, segmentación y seguimiento. Establece fundamento de arquitecturas de un solo paso para procesamiento simultáneo en el conveyor industrial.
Pellegrino, M., et al. (2025). Recycling, 10(5), 179. doi:10.3390/recycling10050179	Enhanced waste sorting technology by integrating hyperspectral and RGB imaging	MDPI. Scopus y Web of Science.	Sistema Visum HSI™ combinando NIR hiperespectral (700–1100 nm) con RGB para clasificación PMD. PLS-DA para modelo de clasificación. Validación con muestras de flujo real de planta recicladora.	Integración RGB+NIR mejora discriminación de PMD frente a modalidades individuales, especialmente para plásticos oscuros. PLS-DA con datos fusionados: >95% pureza en línea de clasificación.	Referencia reciente 2025 sobre sistemas multimodales industriales. Establece estado del arte en integración NIR+RGB. Posiciona el sistema RGB propuesto frente a sistemas premium como TOMRA o Visum HSI™.

ECO-HYBRID Research Group (2025). Sustainability, 17(19), 8761. doi:10.3390/su17198761	ECO-HYBRID: Sustainable waste classification using transfer learning with hybrid and enhanced CNN models	MDPI. Scopus y Web of Science.	11 CNN pre-entrenadas ajustadas (ResNet-50, EfficientNet variantes, DenseNet-201). Ensemble: weighted averaging, soft voting, stacking. Arquitecturas: EcoMobileNet (MobileNetV3+SE) y EcoDenseNet.	Stacking supera modelos individuales. EcoMobileNet: 98,08% exactitud, diseño ligero para dispositivos móviles. Mejora del 3% en accuracy = 135 toneladas adicionales de reciclables por año.	Estado del arte 2025 en ensemble y CNN mejoradas. EcoMobileNet con SE+CBAM supera directamente la arquitectura base MobileNetV2+CBAM de Jin (2023), estableciendo el nivel de referencia que el estudio propuesto debe igualar o superar.
PNUMA (2024). Perspectiva mundial de la gestión de residuos 2024. Programa de las Naciones Unidas para el Medio Ambiente. https://wedocs.unep.org	Perspectiva mundial de la gestión de residuos 2024	PNUMA / UNEP. Informe oficial de Naciones Unidas.	Análisis estadístico global de generación, composición y gestión de RSU en 194 países. Proyecciones hasta 2050. Análisis por región incluyendo América Latina.	Generación global: 2,1 mil millones de toneladas en 2023, proyectada a 3,4 mil millones en 2050. Más del 43% de RSU gestionados inadecuadamente. América Latina: déficits significativos en clasificación automatizada.	Establece el contexto global del problema de investigación. Datos para América Latina validan la relevancia del estudio en el contexto colombiano y fundamentan la urgencia del tema de investigación.