

Matriz de antecedentes

N°	Autores y Año	Título del estudio	Tipo de fuente	Metodología	Principales hallazgos	Relación con la investigación	DOI / Link de consulta
1	Jin, S., Yang, Z., Królczyk, G., Liu, X., Gardoni, P., & Li, Z. (2023). Waste Management, 162, 123–130.	Garbage detection and classification using a new deep learning-based machine vision system as a tool for sustainable waste recycling	Artículo científico	Diseño experimental cuantitativo. CNN MobileNetV2 mejorada con módulo de atención CBAM, reducción dimensional PCA (95% varianza acumulada) y transferencia de aprendizaje. Dataset: HUAWEI-40 (14 683 imágenes, 4 categorías). Comparación frente a AlexNet, VGG16, ResNet50 y ResNet101. Prototipo en Raspberry Pi 4B.	El modelo alcanza 90,7% de exactitud, superando en 19,3 pp a la MobileNetV2 base (71,4%). Tiempo de inferencia de 600 ms en hardware embebido. Compresión del modelo en 30,1% mediante PCA.	Antecedente directo para el diseño de un sistema de clasificación de residuos con visión artificial adaptado al contexto colombiano. Provee la arquitectura base, métricas de evaluación y esquema de validación en dispositivos embebidos.	https://doi.org/10.1016/j.wasman.2023.02.014
2	Rodríguez Chacón, C. (2025). Trabajo de grado. Politécnico Grancolombiano.	Sistema de clasificación de residuos con visión artificial y aprendizaje profundo (WasteCareAI)	Trabajo de grado	YOLOv11 segmentación de instancias. Dataset propio colombiano: 5.340 imágenes, 10 categorías. Entrenamiento en GPU local.	Cartón: 76%, Plástico: 74% mAP@50. Insuficiente para industria (req. >90%). Alta similitud visual PET/PVC es limitación principal.	Línea base colombiana directa. El proyecto de maestría debe superar este umbral. Justifica la brecha nacional identificada en OE1 y OE2.	https://tinyurl.com/43m3s49w
3	Programa de las Naciones Unidas para el Medio Ambiente. (2024). Perspectiva mundial de la gestión de residuos 2024: Más allá de la era de los residuos. PNUMA / ISWA.	Perspectiva mundial de la gestión de residuos 2024: Más allá de la era de los residuos	Artículo científico	Informe técnico global elaborado por PNUMA e ISWA. Diagnóstico del estado de la gestión de residuos a nivel mundial, con datos de 193 países. Análisis de tendencias, políticas y brechas en infraestructura.	Se generan 2.100 millones de toneladas de residuos sólidos municipales al año. El 40% no recibe gestión adecuada. Los países de ingresos bajos y medios son los más afectados. La economía circular emerge como estrategia clave.	Proporciona el contexto global de la problemática de residuos que justifica el desarrollo del sistema propuesto. Sustenta la urgencia de soluciones tecnológicas en países en desarrollo como Colombia.	https://wedocs.unep.org/items/36e16872-2f02-4447-a3c1-c939bf50ea92
4	Kroell, N., Chen, X., Greiff, K., & Feil, A. (2022). Waste Management, 149, 259–290.	Optical sensors and machine learning algorithms in sensor-based material flow characterization for mechanical recycling: A systematic literature review	Artículo científico	Revisión sistemática de literatura sobre sensores ópticos y algoritmos de ML aplicados a caracterización de flujos de materiales en reciclaje mecánico. 2010–2021.	Identifica NIR, hiperspectral y visión RGB como tecnologías dominantes. El 68% de estudios usan CNN. Brecha en integración de múltiples sensores y en condiciones industriales reales.	Marco de referencia para selección de sensores y algoritmos en sistemas automáticos de clasificación de residuos. Orienta la elección tecnológica del sistema propuesto.	https://doi.org/10.1016/j.wasman.2022.05.015
5	Konstantinidis, F., et al. (2023). Resources, Conservation and Recycling, 199, 107244.	Multi-modal sorting in plastic and wood waste streams	Artículo científico	Diseño experimental con sensores multimodales (NIR, RGB, 3D) para clasificación de plástico y madera. Modelos SVM y CNN. Evaluación en línea de producción real.	Precisión superior al 92% combinando NIR y RGB frente al 78% solo con RGB. El enfoque multimodal mejora significativamente la separación de residuos similares.	Justifica la integración de información multimodal en sistemas de clasificación. Evidencia la superioridad de combinar modalidades sensoriales para mejorar la precisión.	https://doi.org/10.1016/j.resconrec.2023.107244
6	Majchrowska, S., et al. (2022). Waste Management, 150, 26–36.	Deep learning-based waste detection in natural and urban environments	Artículo científico	Diseño experimental con modelos de detección de objetos (YOLOv5, Faster R-CNN, SSD) en entornos naturales y urbanos. Datasets TACO, UAVVaste y OpenLitterMap.	YOLOv5 logra mAP de 51,3 en TACO dataset. La detección en entornos no controlados reduce la precisión hasta 30% frente a ambientes de laboratorio.	Evidencia los retos de detección en condiciones no controladas. Orienta el diseño de datasets robustos y estrategias de augmentation para el contexto colombiano.	https://doi.org/10.1016/j.wasman.2022.06.012
7	Bashkirova, D., Abdelfattah, M., Zhu, Z., et al. (2022). CVPR 2022, pp. 21147–21157.	ZeroWaste dataset: Towards deformable object segmentation in cluttered scenes	Artículo de conferencia	Construcción de dataset ZeroWaste con imágenes de plantas de reciclaje industrial. Anotación de segmentación de instancias para objetos deformables en escenas saturadas.	Dataset de referencia para segmentación de residuos en entornos reales. Modelos entrenados logran mAP de 34,8. Demuestra la brecha entre laboratorio e industria.	Dataset de referencia para entrenar y evaluar sistemas de segmentación de residuos en condiciones industriales. Relevante para la creación del dataset colombiano.	https://openaccess.thecvf.com/content/CVPR2022/papers/Bashkirova_ZeroWaste_Dataset_Towards_Deformable_Object_Segmentation_in_Cluttered_Scenes_CVPR_2022_paper.pdf
8	Single, S., Iranmanesh, S., & Raad, R. (2023). Information, 14(12), 633.	RealWaste: A novel real-life data set for landfill waste classification using deep learning	Artículo científico	Construcción de dataset RealWaste con imágenes reales de vertedero (4752 imágenes, 9 categorías). Evaluación con EfficientNetV2, VGG-16, ResNet-50 y DenseNet-201.	EfficientNetV2 logra 85,5% de precisión. El dataset supera a TrashNet en variabilidad y representatividad. Identifica la necesidad de datasets más grandes y balanceados.	Aporta metodología para la construcción de datasets realistas de residuos. Referencia para el diseño del corpus colombiano del sistema propuesto.	https://doi.org/10.3390/info14120633
9	Terven, J., Córdova-Esparza, D., & Romero-González, J. (2023). Machine Learning and Knowledge Extraction, 5(4), 1680–1716.	A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS	Artículo de revisión	Revisión sistemática comparativa de todas las versiones de YOLO (v1–v8 y YOLO-NAS): arquitectura, benchmark en COCO, velocidad y uso de memoria.	YOLOv8 logra 53,9 mAP en COCO con 11,2 ms de latencia. Cada generación mejora el balance velocidad-precisión. YOLO-NAS supera YOLOv8 en precisión con hardware optimizado.	Fundamenta la selección de la arquitectura YOLO para detección de residuos en tiempo real. Permite justificar YOLOv8/v10/v11 como backbone del sistema propuesto.	https://doi.org/10.3390/make5040083

10	Gelar, T., Fitriani, S., & Rachmat, S. (2025). <i>Green Intelligent Systems and Applications</i> , 5(2), 123–139.	A systematic literature review of YOLO and IoT applications in smart waste management	Artículo de revisión	Revisión sistemática de 72 artículos (2018–2024) sobre YOLO aplicado a gestión inteligente de residuos con IoT. Análisis bibliométrico y síntesis temática.	YOLOv5 y YOLOv8 dominan las publicaciones (68%). La integración con IoT mejora la gestión en tiempo real. Brecha en despliegues en países de ingresos bajos.	Contextualiza el uso de YOLO-IoT en gestión de residuos. Identifica la brecha en países en desarrollo, justificando la pertinencia del proyecto en Colombia.	https://tecnoscientifica.com/journal/gisa/article/view/706
11	Lin, K., Zhao, Y., Gao, X., et al. (2022). <i>Environmental Science and Pollution Research</i> , 29, 91081–91095.	Applying a deep residual network coupling with transfer learning for recyclable waste sorting	Artículo científico	Diseño experimental con ResNet-50 y transfer learning aplicado a clasificación de 6 categorías de residuos reciclables. Fine-tuning con TrashNet (2527 imágenes).	Precisión del 94,6% con transfer learning vs. 81,2% sin transfer learning. Reduce el tiempo de entrenamiento en 60%. Mejora significativa en clases subrepresentadas.	Justifica el uso de transfer learning con ResNet para clasificación de residuos. Provee métricas de comparación con y sin transfer learning para datasets pequeños.	https://doi.org/10.1007/s11356-022-22167-w
12	Rahman, M., Islam, R., Hasan, A., et al. (2022). <i>Journal of King Saud University – Computer and Information Sciences</i> , 34(5), 2072–2087.	Intelligent waste management system using deep learning with IoT	Artículo científico	Diseño experimental de sistema integrado deep learning + IoT para clasificación y gestión de residuos en tiempo real. CNN personalizada + sensores IoT. Dataset propio.	Precisión del 93,7% en clasificación de 5 categorías. Reducción del 35% en costos operativos de recolección. Sistema desplegado en entorno real en Bangladesh.	Modelo de integración CNN-IoT aplicable al sistema propuesto. Demuestra viabilidad de despliegue en países en desarrollo con infraestructura limitada.	https://doi.org/10.1016/j.jksuci.2020.08.016
13	Riyadi, S., Andriyani, A., & Masyhur, A. (2024). <i>Revue d'Intelligence Artificielle</i> , 38(4), 1089–1096.	Classification of recyclable waste using deep learning: A comparison of YOLO models	Artículo científico	Comparación experimental de YOLOv5, YOLOv7 y YOLOv8 para clasificación de residuos reciclables. Dataset: 3200 imágenes, 8 categorías. Métricas: mAP, precisión, recall y velocidad.	YOLOv8 supera a YOLOv5 y YOLOv7 en mAP (91,3% vs 87,6% vs 89,1%). Mejor balance velocidad-precisión en hardware embebido. YOLOv5 más liviano para IoT.	Comparativa directa de versiones YOLO en residuos. Orienta la selección de arquitectura para la investigación actual según restricciones de hardware y precisión requerida.	https://doi.org/10.18280/ria.380404
14	Page, M. J., McKenzie, J. E., Bossuyt, P. M., et al. (2021). <i>BMJ</i> , 372, n71.	The PRISMA 2020 statement: an updated guideline for reporting systematic reviews	Declaración metodológica	Declaración metodológica actualizada para la notificación de revisiones sistemáticas. Define 27 ítems de lista de verificación en un diagrama de flujo de cuatro fases.	Adoptado como estándar en más de 300 revistas científicas. Mejora la reproducibilidad y transparencia de revisiones sistemáticas. Reducción de sesgo de notificación en un 40% frente a PRISMA 2009.	Marco metodológico utilizado para estructurar la revisión sistemática de la presente investigación. Garantiza la trazabilidad y reproducibilidad del proceso de búsqueda y selección de antecedentes.	https://doi.org/10.1136/bmj.n71
15	Islam, M., et al. (2025). <i>PLOS ONE</i> , 20(6), e0324294.	Towards sustainable solutions: Effective waste classification framework via enhanced deep CNNs	Artículo científico	Marco de clasificación con CNN mejoradas (EfficientNet-B4, DenseNet-201) y técnicas de augmentation avanzadas. Dataset multiclase (10 categorías). Evaluación en entornos sostenibles.	EfficientNet-B4 logra 96,2% de precisión. El augmentation reduce el sobreajuste en clases subrepresentadas. El marco es replicable y de bajo costo computacional.	Marco de referencia para clasificación de residuos sostenible. Justifica el uso de EfficientNet y augmentation en sistemas con datos limitados para el contexto colombiano.	https://doi.org/10.1371/journal.pone.0324294
16	Alvarado, M., Mosquera, J., & Ríos, G. (2025). <i>Sensors</i> , 25(10), 3181.	A systematic review of AI-based techniques for automated waste classification	Artículo de revisión	Revisión sistemática de 130 artículos (2018–2024) sobre técnicas de IA para clasificación automatizada de residuos. Análisis de arquitecturas, datasets y métricas.	CNN domina con 74% de estudios. YOLOv5/v8 son arquitecturas más frecuentes. Brecha en datasets para países latinoamericanos. Pocos estudios evalúan en hardware embebido.	Panorama actualizado de IA en clasificación de residuos. Evidencia la brecha latinoamericana y valida la pertinencia de crear un dataset colombiano.	https://doi.org/10.3390/s25103181
17	Abdu, H., & Noor, M. (2022). <i>IEEE Access</i> , 10, 128151–128165.	A survey on waste detection and classification using deep learning	Artículo de revisión	Revisión de 100+ estudios sobre detección y clasificación de residuos con deep learning (2015–2022). Taxonomía de métodos, datasets y aplicaciones.	Rápido crecimiento de publicaciones desde 2019. CNN supera SVM en todas las comparativas. Brecha en sistemas desplegados en producción real. Necesidad de datasets diversos.	Survey de referencia que contextualiza el estado del arte en clasificación de residuos con IA. Identifica tendencias y brechas que el sistema propuesto busca cerrar.	https://doi.org/10.1109/ACCESS.2022.3226682
18	Zhao, R., et al. (2024). <i>Waste Management</i> , 190, 398–408.	Multi-target detection of waste composition in complex environments based on an improved YOLOX-S model	Artículo científico	Mejora de YOLOX-S con módulo de atención y detección multi-objetivo para composición de residuos en entornos complejos. Dataset de planta de reciclaje real.	mAP de 58,4% en entornos complejos (vs 51,2% YOLOX-S original). Mejora del 14,1% en detección de objetos pequeños. Velocidad de 43 fps en GPU NVIDIA V100.	Referencia para mejorar la detección de múltiples tipos de residuos en imágenes complejas. Muestra la utilidad de módulos de atención en arquitecturas YOLO para residuos.	https://doi.org/10.1016/j.wasman.2024.06.028
19	Bobulski, J., & Kubanek, M. (2021). <i>Applied Computational Intelligence and Soft Computing</i> , 2021, 6626948.	Deep learning for plastic waste classification system	Artículo científico	Diseño experimental con CNN profunda para clasificación de residuos plásticos. Dataset: 7 categorías de plástico. Comparación con SVM, KNN y Random Forest.	CNN logra 93,2% de precisión vs 71,4% de SVM. Transfer learning mejora el desempeño en clases pequeñas. Primer sistema dedicado exclusivamente a plásticos.	Referencia específica para clasificación de plásticos, categoría crítica en el contexto colombiano. Valida la superioridad de CNN sobre métodos clásicos de ML.	https://doi.org/10.1155/2021/6626948
20	Zhang, Q., Yang, Q., Zhang, X., Bao, Q., Su, J., & Liu, X. (2021). <i>Waste Management</i> , 135, 150–157.	Waste image classification based on transfer learning and convolutional neural network	Artículo científico	Transfer learning con VGG-16 y ResNet-50 para clasificación de imágenes de residuos. Dataset TrashNet ampliado (2527 imágenes, 6 categorías). Análisis de fine-tuning.	VGG-16 con fine-tuning: 92,8% de precisión. ResNet-50: 91,3%. Supera CNN entrenada desde cero en 15 pp con datos limitados. Reduce tiempo de entrenamiento 75%.	Valida la metodología de transfer learning para clasificación de residuos con datasets pequeños. Proporciona el protocolo experimental de referencia para el sistema propuesto.	https://www.sciencedirect.com/science/article/abs/pii/S0956053X21004815
21	Hussain, M. (2024). <i>IEEE Access</i> , 12, 42816–42833.	YOLOv1 to v8: Unveiling each variant – a	Artículo de revisión	Revisión histórica y técnica exhaustiva de las 8 versiones de YOLO. Análisis de	YOLO ha reducido el error de detección en 41% desde v1 a v8. YOLOv8 es el más verstil.	Guía completa para seleccionar la versión de YOLO más adecuada para la investigación actual según las restricciones	https://www.researchgate.net/publication/379088654

		comprehensive review of YOLO		arquitectura, innovaciones, benchmarks COCO y casos de uso industriales.	Cada versión responde a limitaciones específicas de la anterior.	de hardware, velocidad y precisión requerida.	
22	Tian, X., Shi, L., Luo, Y., & Zhang, X. (2024). IEEE Access, 12, 44799–44807.	Garbage classification algorithm based on improved MobileNetV3	Artículo científico	Mejora de MobileNetV3 con módulo de atención CBAM y data augmentation para clasificación de basura en dispositivos móviles. Dataset: 10 categorías, 15 000 imágenes.	Precisión del 93,4% con modelo mejorado (vs 88,1% MobileNetV3 original). Tamaño del modelo: 14,3 MB, apto para smartphones. Inferencia en 48 ms en dispositivo móvil.	Valida el uso de MobileNetV3 con atención para clasificación de residuos en dispositivos de bajo cómputo, compatible con el despliegue del sistema propuesto en Colombia.	https://www.researchgate.net/publication/379274467
23	Feng, Z., Yang, J., Chen, L., Chen, Z., & Li, L. (2022). International Journal of Environmental Research and Public Health, 19(23), 15987.	An intelligent waste-sorting and recycling device based on improved EfficientNet	Artículo científico	Diseño e implementación de dispositivo físico de clasificación de residuos con EfficientNet mejorado y brazo mecánico. Dataset propio de 12 categorías.	Precisión del 95,8% en 12 categorías. Tiempo de clasificación de 1,2 segundos por objeto. Sistema desplegado y probado en entorno universitario en China.	Prototipo de referencia que integra clasificación por visión artificial con actuación mecánica. Sirve como modelo para la fase de implementación del sistema propuesto.	https://doi.org/10.3390/ijerph192315987
24	Neelakandan, S., et al. (2022). Chemosphere, 308, 136046.	Metaheuristics with deep transfer learning enabled detection and classification for industrial waste management	Artículo científico	Combinación de metaheurísticas (algoritmo genético, PSO) con transfer learning (ResNet, DenseNet) para clasificación de residuos industriales. Optimización de hiperparámetros.	Precisión del 97,1% con optimización metaheurística. Mejora del 4,3% vs transfer learning sin optimización. Reducción del tiempo de búsqueda de hiperparámetros en 60%.	Estrategia de optimización aplicable al ajuste de hiperparámetros en el sistema propuesto. Demuestra que la optimización automática mejora significativamente el rendimiento del modelo.	https://doi.org/10.1016/j.chemosphere.2022.136046
25	Li, N., & Chen, Y. (2023). Urban Climate, 49, 101462.	Municipal solid waste classification and real-time detection using deep learning methods	Artículo científico	Sistema de detección y clasificación en tiempo real de residuos sólidos municipales con YOLOv5 y MobileNetV2. Implementación en Raspberry Pi 4 y cámara USB.	Tasa de detección del 91,7% a 24 fps en Raspberry Pi 4. Clasificación de 6 categorías municipales con 88,3% de precisión. Costo total del hardware: USD 120.	Sistema de bajo costo en hardware embebido, directamente comparable al objetivo del sistema propuesto. Valida la viabilidad económica del despliegue en municipios colombianos.	https://www.sciencedirect.com/science/article/abs/pii/S2212095523000561
26	Alrayes, F., Asiri, M., Maashi, M., et al. (2023). Urban Climate, 49, 101483.	Waste classification using vision transformer based on multilayer hybrid convolution neural network	Artículo científico	Modelo híbrido ViT + CNN multicapa (MLHCNN) para clasificación de residuos. Comparación con VGG-16, ResNet-50 y ViT puro en TrashNet y dataset propio.	El modelo híbrido logra 97,3% en TrashNet, superando ViT (94,1%) y ResNet-50 (93,8%). Combina características locales (CNN) y globales (ViT) de forma efectiva.	Justifica la arquitectura híbrida CNN-Transformer para mejorar la clasificación de residuos. Orienta el diseño de modelos que combinen atención global y local.	https://doi.org/10.1016/j.uclim.2023.101483
27	ECO-HYBRID Research Group. (2025). Sustainability, 17(19), 8761.	ECO-HYBRID: Sustainable waste classification using transfer learning with hybrid and enhanced CNN models	Artículo científico	Clasificación sostenible de residuos con modelos CNN híbridos mejorados y transfer learning. 8 categorías. Evaluación de huella de carbono computacional del modelo.	Precisión del 96,5% con menor huella de carbono que modelos de mayor escala. Balance entre rendimiento y sostenibilidad computacional. Primer estudio con métrica de CO2.	Aporta la dimensión de sostenibilidad computacional a la evaluación de modelos para la investigación actual. Relevante para justificar decisiones de diseño con criterios ambientales.	https://doi.org/10.3390/su17198761
28	Kirillov, A., Mintun, E., Ravi, N., et al. (2023). ICCV 2023, pp. 4015–4026.	Segment Anything (SAM)	Artículo de conferencia	Modelo fundacional de segmentación con prompts de punto, caja o texto. Dataset SA-1B: 1100 millones de máscaras en 11 millones de imágenes. Evaluación zero-shot en 23 datasets.	IoU >85% zero-shot en COCO, ADE20K y otros. Supera modelos especializados en algunos benchmarks. Primer modelo fundacional de segmentación de propósito general.	SAM elimina la necesidad de datos anotados específicos para segmentación. Potencial base para anotar automáticamente imágenes de residuos en el dataset colombiano.	https://arxiv.org/abs/2304.02643
29	Consejo Nacional de Política Económica y Social — CONPES. (2016). Documento CONPES 3874. Departamento Nacional de Planeación, Bogotá, Colombia.	Política nacional para la gestión integral de residuos sólidos	Política pública / Documento CONPES	Documento de política pública. Define lineamientos estratégicos para la gestión integral de residuos sólidos en Colombia: metas, responsables, indicadores y plan de acción 2016–2030.	Colombia genera aprox. 12 millones de ton/año de residuos sólidos. Solo el 17% se recicla formalmente. Se establecen metas de aprovechamiento del 20% para 2030 y formalización de recicladores.	Marco normativo nacional que contextualiza la necesidad del sistema propuesto en Colombia. Define las categorías de residuos y los estándares de clasificación vigentes en el país.	https://colaboracion.dnp.gov.co/CDT/Conpes/Econ%C3%B3micos/3874.pdf
30	Ministerio de Vivienda, Ciudad y Territorio. (2013). Decreto 2981 de 2013. República de Colombia, Bogotá.	Decreto 2981 de 2013: Por el cual se reglamenta la prestación del servicio público de aseo	Decreto	Decreto reglamentario. Establece las condiciones técnicas y operativas para la prestación del servicio público de aseo, incluyendo separación en la fuente, recolección selectiva y disposición final de residuos.	Regula la separación en la fuente en Colombia. Define responsabilidades de usuarios, operadores y municipios. Establece la obligatoriedad de rutas de recolección selectiva en municipios de más de 5.000 ciudadanos.	Referente legal obligatorio para el diseño del sistema propuesto. Las categorías de clasificación del sistema deben alinearse con las definiciones de residuos del decreto para garantizar su aplicabilidad legal.	https://www.funcionpublica.gov.co/eva/gestornormativo/norma.php?i=56035
31	Khanam, R., & Hussain, M. (2024). arXiv:2410.17725.	YOLOv11: An overview of the key architectural enhancements	Preprint / arXiv	Descripción de las innovaciones arquitectónicas de YOLOv11: cabezas de detección mejoradas, C3K2 blocks, SPPF extendido. Benchmarks en COCO y comparación con YOLOv8/v10.	YOLOv11 logra 54,7 mAP en COCO (vs 53,9 YOLOv8) con 22% menos parámetros. Mayor precisión en objetos pequeños y ocluidos. Optimizado para edge computing.	Referencia para evaluar la versión más reciente de YOLO en el sistema propuesto. Justifica la elección de YOLOv11 para detección eficiente en hardware embebido.	https://arxiv.org/abs/2410.17725

32	Wang, A., Chen, H., Liu, L., et al. (2024). <i>NeurIPS 2024</i> . arXiv:2405.14458.	YOLOv10: Real-time end-to-end object detection	Preprint / arXiv	YOLOv10 elimina la supresión no máxima (NMS) mediante predicción dual consistente. Evaluación en COCO. Modelos nano (2,3M parámetros) a extra-large.	YOLOv10-S: 46,8 mAP con 15,8 ms latencia (sin NMS). 1,8x más rápido que RT-DETR. Primer detector YOLO sin post-procesamiento manual.	YOLOv10 elimina cuellos de botella de inferencia relevantes para la investigación actual. La eliminación de NMS reduce la latencia total del sistema de clasificación de residuos.	https://arxiv.org/abs/2405.14458
33	Zhou, Y., Lin, L., & Wang, T. (2024). <i>AIP Advances</i> , 14(12), 125012.	Garbage classification detection system based on the YOLOv8 algorithm	Artículo científico	Sistema de detección de basura con YOLOv8 en cámaras de vigilancia urbana. Dataset: 6 categorías de residuos urbanos. Despliegue en servidor NVIDIA Jetson.	Precisión del 92,4% y recall del 89,7%. Velocidad de 67 fps en Jetson AGX Orin. Detección exitosa en condiciones de poca iluminación y oclusión parcial.	Demuestra la aplicabilidad de YOLOv8 en vigilancia urbana para residuos. Evidencia el potencial de integración con sistemas de monitoreo en ciudades colombianas.	https://doi.org/10.1063/5.0244795
34	Tan, M., & Le, Q. (2021). <i>ICML 2021, PMLR vol. 139</i> , pp. 10096–10106.	EfficientNetV2: Smaller models and faster training	Artículo de conferencia	EfficientNetV2 con escalado progresivo de tamaño de imagen durante entrenamiento y Fused-MBConv layers. Comparación en ImageNet, CIFAR-100 y Flowers. Modelos S, M y L.	EfficientNetV2-L: 85,7% en ImageNet con 4x menor tiempo de entrenamiento que EfficientNetV1. Mejor relación precisión/velocidad que ViT y BiT. 11x más rápido en entrenamiento.	EfficientNetV2 es candidato para el backbone del sistema propuesto por su eficiencia computacional y alta precisión. Referencia para comparación con YOLO en clasificación de residuos.	https://proceedings.mlr.press/v139/tan21a.html
35	Mao, W., Chen, W., Wang, C., & Lin, Y. (2021). <i>Resources, Conservation and Recycling</i> , 164, 105132.	Recycling waste classification using optimized convolutional neural network	Artículo científico	CNN con técnicas de optimización (dropout adaptativo, batch normalization mejorado) para clasificación de reciclables. Dataset de 5 categorías, 12 000 imágenes.	Precisión del 95,6% superando CNN estándar en 7,2 pp. El dropout adaptativo reduce el sobreajuste en 23%. Balance óptimo entre profundidad y parámetros del modelo.	Técnicas de optimización de CNN aplicables al entrenamiento del sistema propuesto. Metodología de regularización para mejorar la generalización en el dataset colombiano.	https://doi.org/10.1016/j.resconrec.2020.105132
36	Liang, S., & Gu, Y. (2021). <i>Waste Management</i> , 126, 247–257.	A deep CNN to simultaneously localize and recognize waste types in images	Artículo científico	CNN profunda para localización y reconocimiento simultáneos de tipos de residuos en imágenes. Dataset: 15 categorías, imágenes con múltiples residuos por escena.	mAP de 72,3% para localización y clasificación simultánea. Primera CNN que unifica localización y clasificación de residuos. Mejora del 18% frente a modelos de dos etapas.	Arquitectura unificada de detección y clasificación relevante para la investigación actual. Justifica el enfoque de detección simultánea en lugar de pipelines separados.	https://doi.org/10.1016/j.wasman.2021.03.012
37	Huang, K., Lei, H., Jiao, Z., & Zhong, Z., (2021). <i>Sustainability</i> , 13(21), 11572.	Recycling waste classification using vision transformer on portable device	Artículo científico	Aplicación de Vision Transformer (ViT) en dispositivos portátiles para clasificación de residuos reciclables. Comparación con CNN en hardware de bajo consumo (Raspberry Pi 4).	ViT-S logra 93,7% en dispositivos portátiles con 112 ms por inferencia. Primer estudio de ViT embebido en Raspberry Pi para clasificación de residuos. Superior a MobileNetV2.	Valida la viabilidad de Vision Transformers en hardware embebido, abriendo posibilidades para versiones futuras del sistema propuesto con arquitecturas transformer.	https://www.mdpi.com/2071-1050/13/21/11572
38	kaya, V.(2023). <i>Frontiers in Environmental Science</i> , 11, 1228732.	Classification of waste materials with a smart garbage system for sustainable development: a novel model	Artículo científico	Modelo GCNet que fusiona EfficientNetV2 y ViT para clasificación de residuos. Evaluado en Garbage Classification Dataset (43786 imágenes, 12 categorías).	GCNet: 98,2% de precisión, superando EfficientNetV2 (96,4%) y ViT (95,1%) por separado. La fusión reduce errores en clases visualmente similares en 34%.	Modelo híbrido de referencia para la investigación actual. La fusión EfficientNetV2-ViT es una alternativa superior a YOLO para aplicaciones con mayor disponibilidad computacional.	https://doi.org/10.3389/fenvs.2023.1228732
39	Wu, F., & Lin, H. (2022). <i>Frontiers in Environmental Science</i> , 10, 1043843.	Effect of transfer learning on the performance of VGGNet-16 and ResNet-50 for the classification of organic and residual waste	Artículo científico	Análisis del efecto del transfer learning en VGGNet-16 y ResNet-50 para clasificación de residuos orgánicos vs. residuales. Dataset: 22 500 imágenes, 2 categorías.	ResNet-50 con transfer learning: 95,4% vs 78,3% sin TL. VGGNet-16: 94,1% vs 75,6%. El transfer learning es crítico para datasets de residuos orgánicos con pocas imágenes.	Cuantifica el impacto del transfer learning en clasificación de residuos orgánicos, categoría relevante para el contexto colombiano donde predomina la materia orgánica.	https://doi.org/10.3389/fenvs.2022.1043843
40	Zhang, Q., Yang, Q., Zhang, X., et al. (2022). <i>Resources, Conservation and Recycling</i> , 181, 106235.	A multi-label waste detection model based on transfer learning	Artículo científico	Modelo de detección multi-etiqueta con transfer learning para imágenes con múltiples tipos de residuos simultáneos. Backbone ResNet-101 con cabeza de clasificación multi-label.	mAP de 84,7% en detección multi-etiqueta. Mejora del 26% frente a clasificadores de etiqueta única en escenas con residuos mezclados. Aborda el problema de co-ocurrencia.	Resuelve la clasificación de imágenes con múltiples residuos, escenario habitual en puntos de recolección colombianos. Orienta el diseño multi-etiqueta del sistema propuesto.	https://doi.org/10.1016/j.resconrec.2022.106235
41	Singh, M., et al. (2023). <i>Process Safety and Environmental Protection</i> , 179, 593–602.	Hyperspectral imaging-based classification of post-consumer thermoplastics for plastics recycling using ANN	Artículo científico	Red neuronal artificial (ANN) con imagen hyperspectral (NIR 900–2500 nm) para clasificación de termoplásticos post-consumo. Siete tipos de plástico (PET, HDPE, PVC, etc.).	Precisión del 99,2% en identificación de 7 tipos de termoplásticos. Superior a métodos visuales (72%) y fluorescencia UV (85%). Viabilidad industrial demostrada en línea real.	Referencia para clasificación de plásticos por tipo químico, complementaria al enfoque visual del sistema propuesto. Potencial de integración con sensores NIR en versiones futuras.	https://doi.org/10.1016/j.psep.2023.09.036
42	Tamin, O., Mounq, E., Dargham, J., et al. (2023). <i>International Journal of Electrical and Computer Engineering</i> , 13(3), 3407–3419.	A review of hyperspectral imaging-based plastic waste detection state-of-the-arts	Artículo de revisión	Revisión del estado del arte en detección de plásticos con imagen hyperspectral (2010–2022). Taxonomía de sensores, algoritmos y aplicaciones industriales.	NIR e imagen hyperspectral logran >98% en condiciones controladas. CNN supera SVM y PLS en clasificación multiespectral. Costo de sensores hiperespectrales como barrera principal.	Contextualiza alternativas de detección avanzadas de plásticos. Evidencia el balance costo-precisión relevante para la selección tecnológica del sistema propuesto.	https://doi.org/10.11591/ijece.v13i3.pp3407-3419

43	Taneepanichskul, N., Purkiss, D., & Miodownik, M. (2022). <i>Frontiers in Sustainability</i> , 3, 901885.	A review of sorting and separating technologies suitable for compostable and biodegradable plastic packaging	Artículo de revisión	Revisión de tecnologías de separación de plásticos compostables y biodegradables: NIR, flotación, electrostática y IA. Evaluación de viabilidad comercial y ambiental.	NIR no diferencia plásticos biodegradables de convencionales en 40% de casos. La IA combinada con fluorescencia UV mejora la detección al 91%. Reto creciente por nuevas formulaciones.	Identifica el reto de clasificar plásticos biodegradables vs convencionales, categoría emergente en Colombia. Orienta el diseño de categorías del dataset del sistema propuesto.	https://doi.org/10.3389/frsus.2022.901885
44	Riba, J., Cantero, R., Riba-Mosoll, P., & Puig, R. (2022). <i>Polymers</i> , 14(12), 2475.	Post-consumer textile waste classification through near-infrared spectroscopy using an advanced deep learning approach	Artículo científico	Clasificación de residuos textiles post-consumo con espectroscopía NIR y deep learning (CNN 1D). 6 tipos de fibra textil. Dataset de 1200 muestras espectrales.	Precisión del 97,8% en clasificación de fibras textiles por espectroscopía NIR con CNN. Superior al 89,3% de PLS-DA convencional. Primer estudio CNN en textiles NIR.	Extiende la clasificación de residuos a la categoría textil con métodos espectrales. Referencia para futuras versiones del sistema propuesto que incluyan residuos textiles.	https://doi.org/10.3390/polym14122475
45	Pellegrino, M., et al. (2025). <i>Recycling</i> , 10(5), 179.	Enhanced waste sorting technology by integrating hyperspectral and RGB imaging	Artículo científico	Sistema híbrido que integra imágenes RGB e hiperespectrales para clasificación de residuos. CNN de fusión temprana y tardía. 8 categorías en línea de clasificación industrial.	Fusión tardía: 96,8% de precisión (vs 91,2% solo RGB y 94,5% solo hiperspectral). Primera evaluación sistemática de estrategias de fusión RGB-hiperspectral en residuos.	Demuestra que la fusión de sensores supera a cada modalidad individualmente. Orienta el diseño de versiones mejoradas del sistema propuesto con múltiples cámaras.	https://doi.org/10.3390/recycling10050179
46	Yudin, D., Zakharenko, N., Smetanin, A., et al. (2024). <i>Engineering Applications of Artificial Intelligence</i> .	Hierarchical waste detection with weakly supervised segmentation in images from recycling plants	Artículo científico	Detección jerárquica de residuos con supervisión débil (anotaciones de caja solo) para segmentación en plantas de reciclaje. Modelo jerárquico de categorías gruesas y finas.	mAP de 61,4% con supervisión débil (vs 73,2% con supervisión completa). Reduce el tiempo de anotación en 78%. Primer enfoque jerárquico en plantas de reciclaje.	El aprendizaje con supervisión débil reduce los costos de anotación, crítico para el dataset colombiano de la investigación actual donde los recursos de anotación son limitados.	https://doi.org/10.1016/j.engappai.2023.107542
47	Sayem, F., et al. (2024). <i>Neural Computing and Applications</i> , 36, 24677–24700.	Enhancing waste sorting and recycling efficiency: robust deep learning-based approach for classification and detection	Artículo científico	Enfoque robusto de deep learning para clasificación y detección de residuos con manejo de variabilidad visual y condiciones adversas. Comparación de 8 arquitecturas CNN.	Modelo propuesto: 94,9% en condiciones adversas (iluminación variable, oclusión). Mejora del 12% frente a modelos sin augmentation adversarial. Robustez en entornos reales.	Estrategias de robustez aplicables al sistema propuesto para mejorar el rendimiento en condiciones reales colombianas (variaciones de iluminación, residuos sucios o deteriorados).	https://doi.org/10.1007/s00521-024-10855-2
48	Lahoti, J., Sn, J., Krishna, M., et al. (2024). <i>PeerJ Computer Science</i> , 10, e1957.	Multi-class waste segregation using computer vision and robotic arm	Artículo científico	Sistema de segregación de residuos multiclase con visión artificial y brazo robótico. YOLOv8 para detección y ROS para control del brazo. 6 categorías de residuos domésticos.	Precisión del 91,3% y throughput de 120 objetos/hora. Primer sistema robótico de código abierto para segregación doméstica. Costo de prototipo: USD 850.	Modelo de integración visión-robótica de bajo costo aplicable a puntos de recolección colombianos. Evidencia la viabilidad económica del sistema propuesto con actuación física.	https://doi.org/10.7717/peerj-cs.1957
49	Casao, S., et al. (2024). <i>IROS 2024</i> , pp. 5852–5858. <i>arXiv:2403.18033</i> .	SpectralWaste dataset: Multimodal data for waste sorting automation	Artículo de conferencia	Dataset multimodal SpectralWaste con imágenes RGB, hiperespectrales y de profundidad de residuos en cinta transportadora industrial. 11 categorías, 2000 escenas anotadas.	Primer dataset multimodal público de residuos industriales con datos espectrales. Modelos CNN en RGB alcanzan 78,4% mAP; con hiperspectral el 89,1%. Referencia para benchmarks.	Dataset multimodal de referencia para sistemas de clasificación en cinta transportadora. Metodología de captura multimodal aplicable al diseño del dataset colombiano.	https://arxiv.org/abs/2403.18033
50	Satav, A., Kubade, S., Amrutkar, C., et al. (2023). <i>International Journal on Interactive Design and Manufacturing</i> , 17, 1–18.	A state-of-the-art review on robotics in waste sorting: scope and challenges	Artículo de revisión	Revisión del estado del arte de sistemas robóticos para clasificación de residuos (2015–2022): visión, actuadores, integración IA-robótica y desafíos de implementación.	El 83% de sistemas robóticos de clasificación usan visión artificial. Velocidad promedio: 60 objetos/min. Principal barrera: costo de despliegue y necesidad de dataset local.	Panorama de robótica en clasificación de residuos que contextualiza el alcance y limitaciones del sistema propuesto. Identifica brechas en países en desarrollo como Colombia.	https://doi.org/10.1007/s12008-023-01320-w
51	Hu, Y., Yang, Z., Qu, Q., et al. (2025). <i>Proceedings of the Institution of Mechanical Engineers, Part C</i> .	A new machine vision-based industrial robot system for garbage management	Artículo científico	Sistema robótico industrial de nueva generación con visión artificial para gestión de basura. CNN personalizada + brazo robótico 6-DOF. Evaluación en entorno de fábrica real.	Precisión del 96,3% y velocidad de 180 objetos/hora. Reducción del 42% en errores de clasificación frente al sistema previo. Primer sistema robótico industrial publicado en 2025.	Estado del arte más reciente en robótica de clasificación industrial. Define el benchmark de rendimiento para sistemas como el propuesto orientados a escala industrial.	https://doi.org/10.1177/09544062251339384
52	Ha, V., Thuong, T., & Ha, V. (2023). <i>Lecture Notes in Networks and Systems</i> , 602.	Developing an intelligent waste sorting with 6DOF robotic arm	Artículo de conferencia	Desarrollo de sistema de clasificación de residuos con brazo robótico 6-DOF e inteligencia artificial. YOLOv5 para detección y ROS para control. Prototipo de bajo costo.	Precisión del 88,7% y velocidad de 90 objetos/hora con costo de hardware USD 500. Primer sistema 6-DOF de código abierto para residuos publicado en Asia del Sureste.	Prototipo de bajo costo con brazo 6-DOF relevante para la fase de implementación del sistema propuesto. Demuestra viabilidad en países con recursos limitados similares a Colombia.	https://doi.org/10.1007/978-3-031-22200-9_44
53	Thao, L. (2023). <i>Journal of Material Cycles and Waste Management</i> , 25, 3791–3800.	An automated waste management system using artificial intelligence and robotics	Artículo científico	Sistema automatizado de gestión de residuos con IA y robótica: clasificación, pesaje, geolocalización y reporte. CNN + IoT + robótica integrada. Desplegado en ciudad vietnamita.	Precisión del 90,5% y reducción del 31% en costos de recolección. Sistema en producción real durante 6 meses. Primer sistema integrado IA-robótica-gestión urbana publicado.	Sistema integrado de gestión urbana con IA y robótica, aplicable al contexto colombiano. Modelo de despliegue a escala municipal para el sistema propuesto con gestión de datos.	https://doi.org/10.1007/s10163-023-01796-4
54	Grneva, T., et al. (2026). <i>Mathematics</i> , 14(7), 1176.	Image-based waste classification using a hybrid deep learning	Artículo científico	Arquitectura híbrida de deep learning con transfer learning desplegada en edge AI (NVIDIA Jetson Nano) para clasificación de	Precisión del 94,7% en edge device con 78 ms de latencia. Reduce el consumo energético en 63% frente a inferencia en	Referencia de vanguardia para despliegue edge AI en clasificación de residuos. Valida la estrategia de la investigación actual de	https://doi.org/10.3390/math14071176

		<i>architecture with transfer learning and edge AI deployment</i>		<i>residuos en imágenes. 10 categorías, dataset mixto.</i>	<i>nube. Primera evaluación completa de edge AI en residuos.</i>	<i>procesamiento local con hardware de bajo consumo.</i>	
--	--	---	--	--	--	--	--